


EVALUACIÓN #3a

SISTEMAS DE DETECCIÓN DE INTRUSOS USANDO TÉCNICAS DE MACHINE LEARNING

Prof. Nibaldo Rodríguez A.




OBJETIVO GENERAL

- **Implementar y evaluar un sistema de detección de intrusos usando técnicas de machine learning**


OBJETIVO ESPECÍFICOS

1. **Calibrar los pesos de salida de una red neuronal artificial usando el algoritmo de la pseudo-inversa Moore-Penrose.**
2. **Calibrar los pesos ocultos de una red neuronal artificial usando un algoritmo de optimización de enjambres de partículas.**
3. **Evaluar el rendimiento del IDS usando las métricas de F-score de cada categoría (normal/ataque).**



MACHINE LEARNING (ML)

Prof. Nibaldo Rodríguez A.



MACHINE LEARNING (ML)

DEFINICIÓN:


Capacidad de extraer **Patrones** desde la **Data** para generar su propio conocimiento y tomar decisiones.

Patrones:

Información Relevante dada por un experto o por un algoritmo inteligente


Algoritmo Inteligente:

Capacidad para Hallar una Relación Funcional entre los patrones y diversos posibles resultados

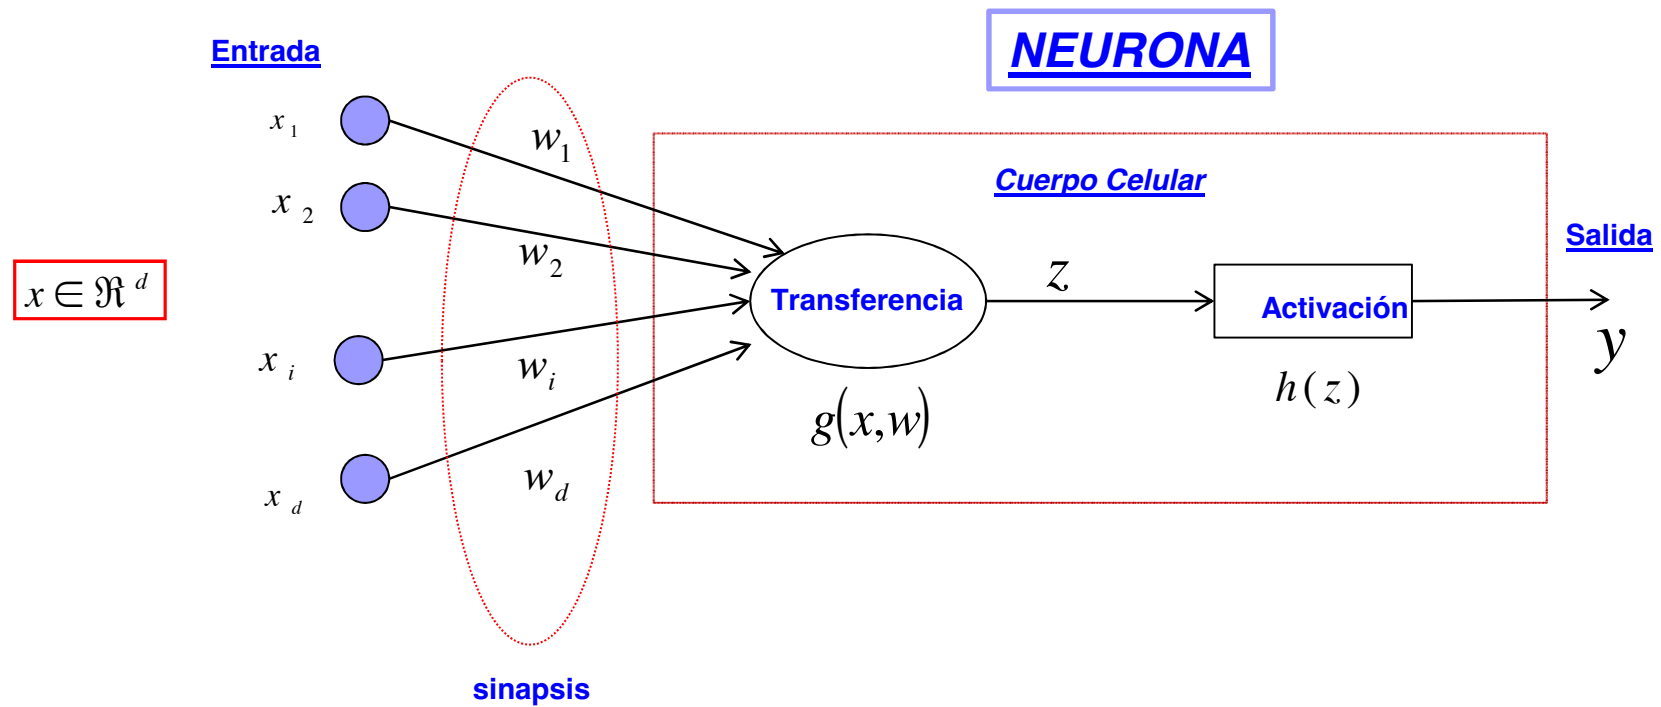



ARTIFICIAL NEURAL NETWORK (ANN)

Prof. Nibaldo Rodríguez A.




Unidad Básica de una ANN

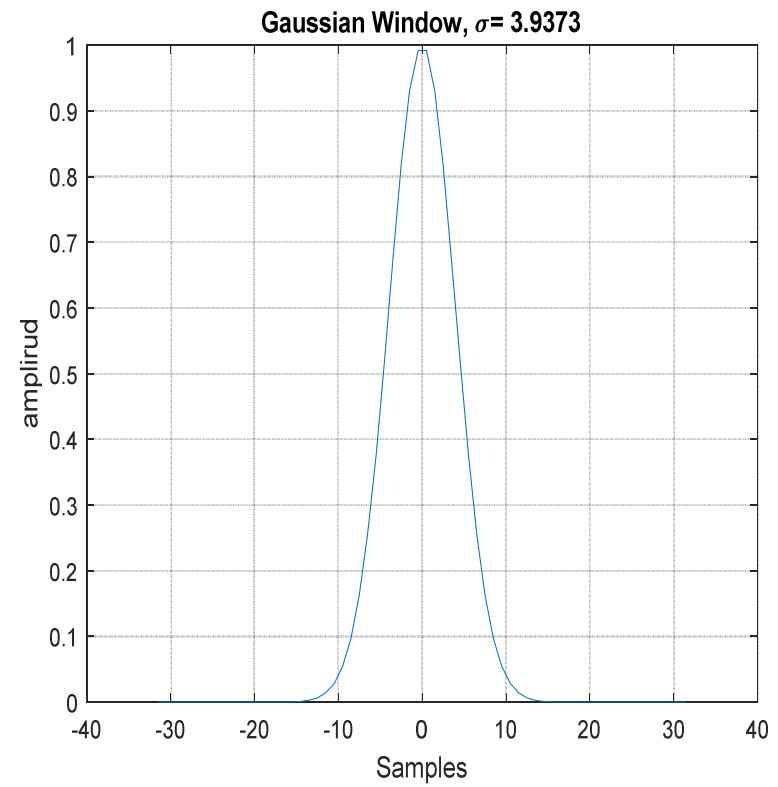





Función Activación



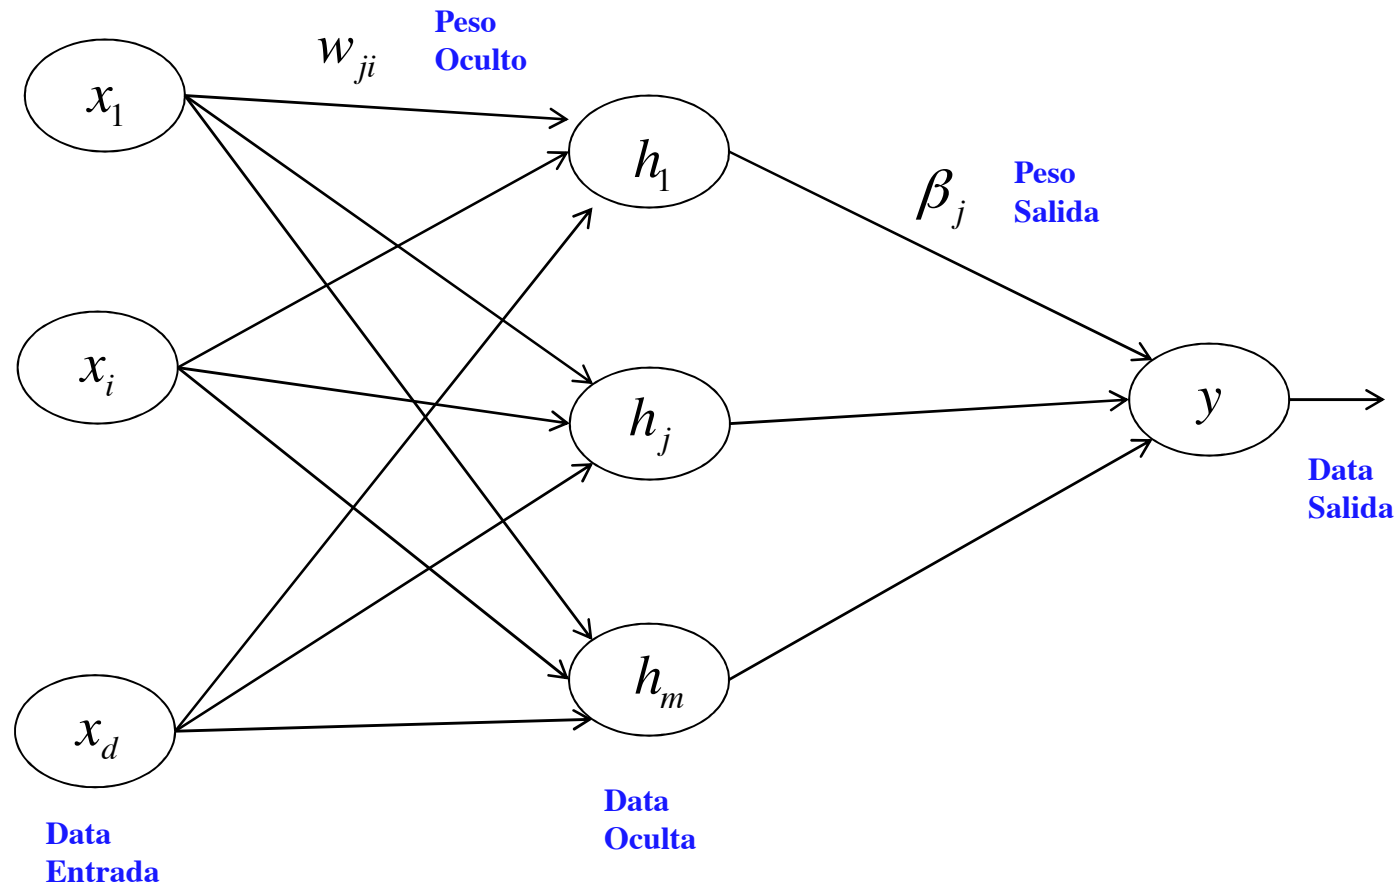
$$F(x) = \frac{1}{1 + e^{-x}}$$




$$F(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-0.5 \frac{x^2}{\sigma^2}\right)$$



Topología de una ANN





FASE #1: Forward de la ANN

- **Step 1:** Activación Capa Oculta

- **d:** nodos de entradas
- **m:** nodos ocultos
- **N:** Número de muestras

$$X \in \mathfrak{R}^{(d \times N)}$$

$$w \in \mathfrak{R}^{(m \times d)}$$

$$H = h(w, X), H \in \mathfrak{R}^{(m \times N)}$$

- **Step 2:** Activación Capa Salida


- Un nodo de salida

$$\beta \in \mathfrak{R}^{(1 \times m)}$$

$$y = \beta \times H, y \in \mathfrak{R}^{(1 \times N)}$$

Función de Activación


$$h(w, X) = ?$$



Red Neuronal Artificial (ANN)

1.- Función de Transferencia y Activación


$$h(w, X) = \frac{1}{1 + \exp[-(w \times X)]}$$



Red Neuronal Artificial (ANN)

2.- Función de Transferencia y Activación


$$h(w, X) = \frac{e^{(w \times X)} - e^{(-w \times X)}}{e^{(w \times X)} + e^{(-w \times X)}}$$



Red Neuronal Artificial (ANN)

3.- Función de Transferencia y Activación


$$h(w, X) = \exp \left(- \frac{1}{2} \|X - w\|^2 \right)$$



Red Neuronal Artificial (ANN)

4.- Función de Transferencia y Activación


$$h(w, X) = (1 - \|x - w\|) \times \exp\left(-\frac{1}{2}\|x - w\|^2\right)$$



(ANN)

5.- Función de Transferencia y Activación


$$h(w, X) = \cos(5 \times \|X - w\|) \times \exp\left(-\frac{1}{2} \|X - w\|^2\right)$$



Red Neuronal Artificial (ANN)

6.- Función de Transferencia y Activación

$$h(w, X) = \left(1 + \|x - w\|\right)^{-\frac{1}{2}}$$




(ANN)

7.- Función de Transferencia y Activación

$$z = w \times X$$

$$h(w, X) = \max \{0.1 \times z, z\}$$



FASE #2: Entrenar la SNN

**APRENDIZAJE SUPERVISADO:
(calibración de los pesos)**



Optimización de Pesos de Salida: Pseudo-inversa Moore-Penrose


$$\beta = \left(H \times H^T + \frac{I}{C} \right)^{-1} H \times Y^T$$
$$C \in [10, 10^8]$$

- **H** = matriz de data de los nodos ocultos.
- **I** = matriz de identidad de tamaño **m**.
- **Y** = datos deseado (target, categoría).
- **()^T** = transpuesta de una matriz.
- **()⁻¹** = matriz pseudo-inversa.
- **C** = parámetro de penalidad de pseudo-inversa.



Optimización Pesos Ocultos.

- 1. Particle Swarm Optimization (PSO)**
- 2. Quantum Particle Swarm Optimization (QPSO)**



Particle Swarm Optimization (PSO)


ENJAMBRE

Mejor Partícula Individual: $p = [w_1, w_2, \dots, w_D]$, $p \in \mathcal{R}^{(1 \times D)}$, $D = (m \times d)$

Mejor Partícula Global: $p_g = [w_1, w_2, \dots, w_D]$, $p_g \in \mathcal{R}^{(1 \times D)}$

Enjambre:
Np: Número de partículas

$$X = \begin{bmatrix} w_{1,1} & w_{1,2} & \dots & \dots & w_{1,D} \\ w_{2,1} & w_{2,2} & \dots & \dots & w_{2,D} \\ \dots & \dots & \dots & \dots & \dots \\ \dots & \dots & \dots & \dots & \dots \\ w_{N_p,1} & w_{N_p,2} & \dots & \dots & w_{N_p,D} \end{bmatrix}$$



Particle Swarm Optimization (PSO)


ENJAMBRE INICIAL

Generar partículas aleatorias:

$$X(i,:) = w, \quad i = 1, \dots, N_p$$

$$w = rand(m, d) \times 2 \times r - r$$

$$r = \sqrt{\frac{6}{m + d}}$$




Particle Swarm Optimization (PSO)

Actualización del Enjambre

Iteración: k -ésima

$$X(k+1) = X(k) + V(k+1)$$

$V = \text{velocidad}$



Particle Swarm Optimization (PSO)

VELOCIDAD

$$V(k+1) = \alpha \times V(k) + c_1 r_1 [P(k) - X(k)] + c_2 r_2 [p_g(k) - X(k)]$$


Inercia: $\alpha \in (0,1)$ $c_1 = 1.05$ $c_2 = 2.95$ $r_1, r_2 \in rand(0,1)$

INERCIA

$$\alpha = \alpha_{\max} - \left(\frac{\alpha_{\max} - \alpha_{\min}}{IterMax} \right) \cdot IterActual \quad \alpha_{\min} = 0.1 \quad \alpha_{\max} = 0.95$$

Partículas Inicial del Enjambre

$$P(0), V(0) = 0 \in \Re^{(N_p \times D)}, \quad p_g(0) = 0 \in \Re^{(1 \times D)}$$



Quantum –PSO (QPSO)


ENJAMBRE INICIAL

Generar partículas aleatorias:

$$X(i,:) = w, \quad i = 1, \dots, N_p$$

$$w = rand(m, d) \times 2 \times r - r$$

$$r = \sqrt{\frac{6}{m + d}}$$



Quantum –PSO (QPSO)

NUEVO ENJAMBRE


Iteración: k -ésima

$$X_{ij} = \begin{cases} P_{i,j}(k) + \alpha \cdot |mBest_j - X_{ij}| \cdot Ln\left(\frac{1}{\mu}\right) & Si \ rand > 0.5 \\ P_{i,j}(k) - \alpha \cdot |mBest_j - X_{ij}| \cdot Ln\left(\frac{1}{\mu}\right) & o.c \end{cases}$$

Partículas del Enjambre

$$P_{i,j}(k) = \varphi \times P_{i,j}(k-1) + (1-\varphi) \times p_{g,j} \quad \varphi, \mu \in rand(0,1)$$

$$P(0) = 0 \in \Re^{(N_p \times D)}, \quad p_g(0) = 0 \in \Re^{(1 \times D)}$$



Quantum –PSO (QPSO)

$$mbest_j = \frac{1}{N_p} \sum_{i=1}^{N_p} p_{i,j}, \quad j = 1, \dots, D$$

$$\alpha = (b - a) \left[\frac{MaxIter - iter}{MaxIter} \right] + a, \quad a = 0.2 \quad b = 0.95$$



Training para PSO-QPSO

Minimizar Función de Costo: MSE

$$E = \frac{1}{N} \sum_{n=1}^N e^2(n)$$
$$e(n) = d(n) - y(n),$$

$d(n)$: valor deseado $y(n)$ = valor de salida de la red

N = Num. muestras de training



Evaluación de Rendimiento

Matriz de Confusión		Valor Real	
		P	N
P R E D I C H O	P	VP	FP
	N	FN	TN

$$P = \frac{VP}{VP + FP}$$

Precision
(precisión)

$$R = \frac{VP}{VP + FN}$$

Recall
(sensibilidad)

$$F = 2 \times \frac{P \times R}{P + R}$$

F-score

$$A = \frac{VP + VN}{VP + FP + VN + FN}$$

Accuracy
(exactitud)



CONTINUARÁ....